

Relatório de Limpeza e Correções da Base de Dados

1. Introdução

Este relatório documenta o processo de limpeza, normalização e correção da base de dados de exportação/importação (2014 a 2024). O objetivo principal é garantir a integridade e a qualidade dos dados utilizados na análise do comércio exterior, proporcionando informações confiáveis e eliminando possíveis distorções que possam impactar a tomada de decisão.

2. Metodologia

- **Ferramenta Utilizada:** Google Colab, com scripts em Python para leitura, análise e transformação dos dados.
- **Fonte dos Dados:** Base pública de comércio exterior disponibilizada pelo Ministério do Desenvolvimento, Indústria, Comércio e Serviços.
- **Processo Realizado:**
 - Carregamento do arquivo CSV.
 - Análise exploratória para identificação de inconsistências e dados irrelevantes.
 - Aplicação de filtros e remoção de registros duplicados ou com valores críticos nulos.
 - Padronização de códigos e unidades.
 - Exclusão de colunas e registros que não agregam valor à análise.

3. Problemas Encontrados

Durante o processo de análise e limpeza, foram identificadas diversas inconsistências na base de dados, tais como:

- **Dados Duplicados:** Registros repetidos que poderiam comprometer a precisão das análises.

- **Valores Nulos ou Inconsistentes:** Algumas colunas apresentavam informações críticas ausentes ou com valores mal formatados.
- **Colunas Irrelevantes:** A presença de informações que não agregavam valor à análise, como descrições em idiomas estrangeiros e códigos internos sem aplicabilidade no contexto do projeto.
- **Códigos de Vias de Transporte Pouco Relevantes:** Algumas vias de transporte estavam classificadas de forma imprecisa ou representavam modalidades que não impactam diretamente o comércio exterior em larga escala.

4. Correções Realizadas

Para resolver os problemas identificados, foram implementadas as seguintes correções:

- **Remoção de Registros Duplicados:** Garantindo que cada produto seja contado apenas uma vez.
- **Tratamento de Valores Nulos:** Removendo registros com ausência de informações essenciais ou aplicando imputação quando viável.
- **Exclusão de Colunas Não Relevantes:** Removendo informações em idiomas estrangeiros (NO_NCM_ESP, NO_NCM_ING) e códigos internos sem impacto na análise.
- **Padronização de Códigos e Unidades:** Garantindo consistência na estrutura dos dados para facilitar consultas e análises futuras.
- **Eliminação de Códigos de Vias de Transporte Pouco Relevantes:**

Vias de Transporte Removidas

Os seguintes códigos de vias de transporte foram excluídos da análise por serem considerados irrelevantes ou imprecisos:

- **00 - VIA NÃO DECLARADA:** Informação genérica, sem utilidade para análises.
- **09 - MEIOS PRÓPRIOS:** Representa transporte não padronizado e difícil de quantificar.
- **10 - ENTRADA/SAÍDA FICTA:** Possivelmente relacionado a processos administrativos, sem impacto real no transporte de mercadorias.

- **99 - VIA DESCONHECIDA:** Classificação imprecisa, podendo distorcer os resultados.
- **12 - EM MÃOS:** Pouco relevante para o comércio exterior em larga escala.
- **11 - COURIER:** Voltado para pequenas encomendas, não representando grandes fluxos de comércio.
- **05 - POSTAL:** Similar ao COURIER, mais relevante para remessas individuais do que para movimentação de cargas em grande escala.

A remoção dessas vias permite uma análise mais precisa dos principais modais de transporte utilizados no comércio exterior brasileiro.

5. Impactos na Análise Final

As correções realizadas resultaram em uma base de dados mais limpa e confiável, com os seguintes benefícios:

- **Aprimoramento da Qualidade dos Dados:** Eliminação de ruídos e inconsistências, garantindo maior precisão na análise.
- **Maior Clareza nas Informações:** Redução de colunas e códigos desnecessários, permitindo que os dados mais relevantes sejam destacados.
- **Facilidade na Integração com Outras Ferramentas:** A estrutura organizada facilita o uso dos dados em dashboards e no Power BI.
- **Melhoria na Tomada de Decisão:** Com dados limpos e bem categorizados, as análises poderão oferecer insights mais assertivos.

6. Conclusão

A aplicação dos processos de limpeza e normalização na base de dados de exportação e importação trouxe melhorias significativas na qualidade da informação. A remoção de vias de transporte irrelevantes, o tratamento de registros duplicados e a padronização dos códigos garantem que a análise do comércio exterior seja feita com maior precisão e confiabilidade.

Com essas melhorias, a plataforma poderá oferecer visualizações e análises mais eficazes, atendendo às necessidades do cliente e possibilitando um entendimento mais claro dos fluxos de comércio no Brasil.

